

דו"ח מסכם-ניתוח נתונים:

החלטות שנלקחו בבניית סט הנתונים:

1. החלטנו לעשות את הסינונים הרלוונטיים לסרטים ישר לאחר טעינת טבלת basics, על מנת שלא ניצור עומס על המחשב ועל הזיכרון שלו. דבר זה עזר גם בטעינה מהירה יותר של שאר הטבלאות מכיוון שהיו פחות סרטים לטעון.
2. את המספר המזהה של 5 השחקנים המובילים הבאנו בעזרת איחוד רשימות השחקנים ומיון לפי מספר הסרט ולפי עמודת ה-ordering כך שהשחקנים הראשיים ביותר ממוקמים בראש הרשימה. חילקנו את הנתונים לקבוצות לפי סרט, שלפנו רק את 5 השחקנים הראשונים מכל קבוצה ואספנו את מספרי הזיהוי שלהם לתוך רשימה.
3. הבאת הנתונים מוויקיפדיה: הבאת הנתונים מוויקיפדיה פגשה אותנו עם מספר קשיים ולכן נלקחו כמה החלטות.
 - הבנו שוויקיפדיה קוראת לערך של סרט במספר אופציות שונות כמו שם הסרט ושנת יציאתו או שם הסרט ו-film). לכן ניסינו את שלוש האופציות המוכרות ביותר בהרצה ראשונית למציאת הערך.
 - הוספנו req_headers כדי "לשקר" לשרתים של ויקיפדיה ולהציג את הסקריפט שלנו כגולש אנושי שמשתמש בדפדפן כרום בווינדוס. זה מונע חסימה אוטומטית של הבוט.
 - במקום לחפש שמות עמודות זהים לחלוטין, הקוד מחפש חלקי מילים. לדוגמה: הוא מזהה את ארץ המקור גם אם כתוב "Country", "Countries", "Origin" או "Nation" מה שפותר בעיות של חוסר אחידות בין סרטים.
 - הקוד לא לוקח רק את הפסקה הראשונה, אלא רץ קדימה ואוסף את כל פסקאות הטקסט (<p>) של העלילה עד שהוא פוגש בכותרת חדשה. (<h2>) זה מבטיח איסוף של כל התוכן גם בסרטים עם עלילה המחולקת לחלקים.
 - בחרנו להביא את הערכים מוויקיפדיה בעזרת צ'אנקים של 500 ערכים על מנת לא ליצור עומס על המחשב ולמנוע חסימה מוויקיפדיה. זאת גם הסיבה שיצרנו השהייה.
4. יצרנו פונקציה שממירה את כל סכומי התקציב וההכנסות לפורמט מספרי אחיד של מיליוני דולרים. זה יאפשר לנו לבצע השוואות, חישובים סטטיסטיים ומודלים בהמשך, במקום להתמודד עם מחרוזות טקסט מבולגנות.
5. יצרנו מילון רחב הממיר מעל 30 סמלי מטבעות וקיצורים לשער הדולר. זה מאפשר לנתח סרטים בינלאומיים.

תיאור שדות סט הנתונים:

Column	description	type	source
tconst	מספר מזהה של הסרט	string	IMDb
primaryTitle	שם הסרט	string	IMDb
startYear	שנת יציאה	Integer	IMDb
genres	ז'אנר	string	IMDb
lead_actors_ids	מספר מזהה של 5 השחקנים המובילים	List of strings	IMDb

runtimeMinutes	מסך הסרט בדקות	Integer	IMDb
averageRating	הדירוג הממוצע	float	IMDb
Language	השפה הראשית בסרט	string	Wikipedia
Country	המדינה בה נוצר הסרט	string	Wikipedia
numVotes	מספר המדרגים	Integer	IMDb
budget	תקציב הפקה במיליוני דולרים (USD)	float	Wikipedia
BoxOffice	הכנסות גלובליות במיליוני דולרים	float	Wikipedia
plot	תקציר הסרט	string	Wikipedia

מספר סרטים שנאספו:

בסך הכל נאספו 5000 הסרטים המדורגים ביותר ומכך גם הפופולריים ביותר.

אחוז ומספר הערכים החסרים בכל עמודה:

	Missing Count	Percentage (%)
budget	3699	73.98
BoxOffice	3489	69.78
plot	3228	64.56
Country	3211	64.22
Language	3203	64.06

